

LAPORAN

SISTEM REKOMENDASI STRATEGI PENINGKATAN KEPUASAN PELANGGAN RESTORAN



Disusun Oleh:

Ayumi Fathiyaraisha (140810230012)
Wa Ode Zachra Chaerani (140810230062)
Maritza Ratnamaya Nugroho (140810230076)

UNIVERSITAS PADJADJARAN

FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
PROGRAM STUDI S-1 TEKNIK INFORMATIKA

2025

DAFTAR ISI

DAFTAR ISI.....	2
BAB I PENDAHULUAN.....	4
1.1. Latar Belakang.....	4
1.2. Rumusan Masalah.....	5
1.3. Tujuan.....	5
BAB II TINJAUAN PUSTAKA.....	6
2.1. Decission Support System (DSS).....	6
2.2. Machine Learning dalam Sistem Pendukung Keputusan.....	6
2.3. Extreme Gradient Boosting (XGBoost).....	6
2.4. Multi-Criteria Decision Making (MCDM).....	7
2.5. Technique for Order Preference by Similarity to Ideal Solution (TOPSIS).....	7
BAB III METODOLOGI.....	8
3.1. Deskripsi Dataset.....	8
3.1.1. Sumber Dataset.....	8
3.1.2. Struktur dan Kualitas Dataset.....	8
3.2. Pelatihan Model XGBoost.....	8
3.3. Metode Pengambilan Keputusan TOPSIS.....	9
3.4. Integrasi XGBoost dan TOPSIS dalam Decision Support System.....	10
BAB IV HASIL DAN DISKUSI.....	11
4.1. Hasil Pengolahan Data dan Pembentukan Model.....	11
4.2. Hasil Pelatihan dan Optimasi Model XGBoost.....	11
4.3. Analisis Hasil Prediksi dan Confusion Matrix.....	12
4.4. Analisis Kurva ROC dan Threshold Keputusan.....	12
4.5. Implementasi Sistem Pendukung Keputusan Berbasis Web.....	13
4.6. Diskusi Hasil.....	15
BAB V KESIMPULAN.....	16
5.1. Kesimpulan.....	16
5.2. Saran.....	16

DAFTAR PUSTAKA.....	17
----------------------------	-----------

BAB I

PENDAHULUAN

1.1. Latar Belakang

Di era digital saat ini, industri kuliner menghadapi persaingan yang sangat ketat. Restoran tidak lagi bisa hanya mengandalkan intuisi dalam menentukan strategi pemasaran, mereka membutuhkan pendekatan berbasis data (*data-driven*) untuk memahami preferensi konsumen dan meningkatkan volume penjualan. Sistem pendukung keputusan merupakan salah satu inovasi penting dalam dunia bisnis yang mampu mengolah data dan menghasilkan rekomendasi guna membantu pengambil keputusan dalam situasi yang kompleks dan tidak terstruktur. DSS modern kini mengintegrasikan teknik analisis data, statistik, dan algoritma *machine learning* untuk meningkatkan akurasi prediksi dan relevansi keputusan bisnis (Kovari, 2024).

Restoran perlu memahami perilaku pelanggan, tingkat kepuasan, dan pola pembelian untuk menentukan strategi yang tepat dalam meningkatkan penjualan dan loyalitas pelanggan. Data survei kepuasan pelanggan, transaksi penjualan, serta variabel operasional lainnya menyediakan informasi berharga yang jika diolah dengan baik dapat menjadi dasar keputusan strategis. DSS berbasis *machine learning* memungkinkan pengolahan data tersebut menjadi rekomendasi yang actionable dan objektif.

Metode *machine learning* seperti Extreme Gradient Boosting (XGBoost) telah terbukti efektif dalam berbagai konteks prediksi bisnis karena kemampuannya menangani data yang bersifat kompleks dan tidak linier, serta memberikan performa prediktif yang tinggi dibandingkan algoritma tradisional. Dalam aplikasi peramalan penjualan dan perilaku pelanggan, XGBoost sering digunakan untuk menganalisis variabel penting dan memprediksi outcome yang relevan bagi strategi bisnis, seperti prediksi permintaan atau *churn* pelanggan (Dairu & Shilong, 2021).

Selain prediksi, keputusan akhir dalam bisnis seringkali harus mempertimbangkan lebih dari satu kriteria yang saling bertentangan. Multiple Criteria Decision Making (MCDM) merupakan pendekatan yang efektif untuk mengevaluasi alternatif berdasarkan banyak kriteria, salah satunya menggunakan metode Technique for Order Preference by Similarity to Ideal Solution (TOPSIS). Implementasi TOPSIS memungkinkan organisasi untuk mengevaluasi pilihan strategi dengan mempertimbangkan kriteria kuantitatif dan kualitatif yang beragam (Rogawati et al., 2023).

Dalam penelitian ini, dikembangkan sebuah sistem DSS berbasis web yang memadukan manajemen data survei kepuasan pelanggan, prediksi model XGBoost, dan perhitungan TOPSIS untuk membantu staff pemasaran atau strategi restoran dalam menentukan strategi pengembangan penjualan yang tepat. Sistem ini bertujuan meningkatkan efektivitas keputusan dalam perencanaan pemasaran restoran melalui pendekatan berbasis data.

1.2. Rumusan Masalah

Berdasarkan latar belakang penelitian, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana mengembangkan Decision Support System (DSS) berbasis web untuk mendukung pengambilan keputusan strategi pengembangan restoran berbasis data?
2. Bagaimana penerapan metode XGBoost dalam memprediksi nilai kriteria dari data survei kepuasan pelanggan?
3. Bagaimana integrasi hasil prediksi XGBoost dengan metode TOPSIS dalam menentukan strategi pengembangan restoran yang optimal?

1.3. Tujuan

Adapun tujuan dari penelitian ini adalah sebagai berikut:

1. Mengembangkan DSS berbasis web untuk membantu staf strategi atau pemasaran restoran dalam menentukan strategi pengembangan penjualan.
2. Menerapkan XGBoost sebagai model prediksi untuk menghasilkan nilai kriteria berbasis data survei kepuasan pelanggan.
3. Mengintegrasikan TOPSIS sebagai metode pengambilan keputusan akhir untuk menentukan prioritas strategi pengembangan penjualan restoran.

BAB II

TINJAUAN PUSTAKA

2.1. Decision Support System (DSS)

Decision Support System (DSS) merupakan sistem berbasis komputer yang dirancang untuk membantu pengambil keputusan dalam menyelesaikan permasalahan semi-terstruktur dan tidak terstruktur dengan memanfaatkan data, model, serta metode analisis tertentu. DSS bertujuan untuk meningkatkan kualitas keputusan dengan menyediakan informasi yang relevan, analisis alternatif, serta rekomendasi yang objektif bagi penggunanya (Kovari, 2024).

Dalam bidang bisnis dan jasa, DSS banyak diterapkan untuk mendukung perencanaan strategis, evaluasi kinerja, dan pemilihan alternatif terbaik. Rogawati et al. (2023) menunjukkan bahwa penerapan DSS pada industri restoran mampu membantu pemilik atau manajer restoran dalam menentukan rekomendasi terbaik berdasarkan berbagai kriteria yang relevan, seperti kualitas layanan dan preferensi pelanggan. Hal ini membuktikan bahwa DSS memiliki peran penting dalam mendukung pengambilan keputusan yang lebih terstruktur dan berbasis data di sektor kuliner.

2.2. Machine Learning dalam Sistem Pendukung Keputusan

Machine learning merupakan pendekatan kecerdasan buatan yang memungkinkan sistem untuk mempelajari pola dari data historis dan menghasilkan prediksi tanpa aturan eksplisit yang ditentukan sebelumnya. Dalam DSS modern, *machine learning* digunakan untuk meningkatkan kemampuan analisis prediktif sehingga keputusan yang dihasilkan menjadi lebih akurat dan adaptif terhadap perubahan data.

Penggunaan machine learning dalam DSS memberikan keunggulan dalam menangani data berskala besar dan kompleks, termasuk data dengan hubungan non-linier. Dalam konteks restoran, machine learning dapat digunakan untuk memprediksi tingkat kepuasan pelanggan berdasarkan karakteristik pelanggan, pola kunjungan, dan penilaian terhadap layanan, yang selanjutnya dapat dijadikan dasar dalam penentuan strategi pengembangan usaha.

2.3. Extreme Gradient Boosting (XGBoost)

Extreme Gradient Boosting (XGBoost) merupakan algoritma machine learning berbasis *ensemble learning* yang menggabungkan banyak pohon keputusan untuk menghasilkan model prediksi yang kuat. Algoritma ini bekerja dengan prinsip boosting,

yaitu membangun model secara bertahap dengan meminimalkan kesalahan pada iterasi sebelumnya melalui optimasi fungsi objektif dan regularisasi (IBM, n.d.).

XGBoost dikenal memiliki performa prediksi yang tinggi, efisiensi komputasi yang baik, serta kemampuan dalam menangani data yang tidak seimbang. Menurut Dairu dan Shilong (2021), XGBoost terbukti efektif dalam berbagai aplikasi bisnis, termasuk peramalan penjualan dan analisis perilaku pelanggan, karena mampu menangkap pola kompleks dalam data. Oleh karena itu, XGBoost dipilih dalam penelitian ini sebagai model prediksi untuk menghasilkan nilai kepuasan pelanggan yang akan digunakan sebagai input dalam proses pengambilan keputusan.

2.4. Multi-Criteria Decision Making (MCDM)

Multi-Criteria Decision Making (MCDM) merupakan pendekatan pengambilan keputusan yang digunakan ketika suatu permasalahan melibatkan lebih dari satu kriteria yang harus dipertimbangkan secara simultan. Kriteria tersebut dapat bersifat saling mendukung maupun saling bertentangan, sehingga diperlukan metode yang mampu memberikan evaluasi secara objektif terhadap setiap alternatif.

Dalam DSS, MCDM berperan penting dalam proses evaluasi dan pemeringkatan alternatif keputusan. Metode MCDM banyak digunakan dalam konteks pemilihan strategi bisnis karena mampu mengakomodasi berbagai faktor penilaian secara bersamaan, seperti kualitas layanan, harga, waktu tunggu, dan kenyamanan pelanggan.

2.5. Technique for Order Preference by Similarity to Ideal Solution (TOPSIS)

Technique for Order Preference by Similarity to Ideal Solution (TOPSIS) merupakan salah satu metode MCDM yang menentukan peringkat alternatif berdasarkan kedekatannya dengan solusi ideal positif dan jaraknya dari solusi ideal negatif. Alternatif terbaik adalah alternatif yang memiliki jarak paling dekat dengan solusi ideal positif dan jarak paling jauh dari solusi ideal negatif (Madanchian & Taherdoost, 2023).

Keunggulan TOPSIS terletak pada konsep perhitungan yang sederhana, transparan, dan mudah diimplementasikan. Selain itu, TOPSIS mampu menangani kriteria bertipe benefit dan cost secara bersamaan. Muin dan Amin (2022) serta Rogawati et al. (2023) menunjukkan bahwa TOPSIS efektif digunakan dalam DSS untuk menentukan rekomendasi atau prioritas keputusan di bidang kuliner dan layanan, sehingga metode ini relevan untuk diterapkan dalam penelitian ini.

BAB III

METODOLOGI

3.1. Deskripsi Dataset

3.1.1. Sumber Dataset

Dataset yang digunakan dalam penelitian ini diperoleh dari Kaggle dengan judul “Predict Restaurant Customer Satisfaction Dataset” yang disediakan oleh Rabie El Kharoua pada tahun 2024 ([link dataset](#)). Dataset ini dipilih karena memiliki berbagai fitur yang relevan dengan kebutuhan pengembangan, salah satunya adalah fitur hasil prediksi kepuasan pelanggan yang bisa digunakan sebagai variabel target saat membuat model (Kharoua, 2024).

3.1.2. Struktur dan Kualitas Dataset

Dataset disajikan dalam format CSV dan terdiri dari 1500 data dengan 19 atribut, yaitu CustomerID, Age, Gender, Income, VisitFrequency, AverageSpend, PreferredCuisine, TimeOfVisit, GroupSize, DiningOccasion, MealType, OnlineReservation, DeliveryOrder, LoyaltyProgramMember, WaitTime, ServiceRating, FoodRating, AmbianceRating, HighSatisfaction.

Pada dataset tidak ditemukan missing value ataupun duplikasi data. Namun, ada beberapa kolom yang terdapat ketidakseimbangan distribusi data, di mana sebagian besar nilai didominasi oleh kategori tertentu, sementara kategori lainnya memiliki proporsi yang relatif kecil.

3.2. Pelatihan Model XGBoost

Metode XGBoost (*eXtreme Gradient Boosting*) digunakan sebagai algoritma prediksi untuk menghasilkan output nilai kriteria atau *score* berdasarkan pola dalam data survei. XGBoost merupakan algoritma *ensemble learning* yang menghasilkan model kuat dari kombinasi beberapa *weak learners* (pohon keputusan) dan dikenal unggul dalam menangani data kompleks dan beragam fitur (Kavlakoglu & Russi, 2025).

Alur pelatihan model adalah sebagai berikut:

1. Prapemrosesan Data

Melakukan pembersihan data dengan penanganan *missing value* (median untuk data numerik dan modus untuk data kategorikal) serta transformasi atribut kategorikal menjadi numerik menggunakan *label encoding*.

2. Rekayasa Fitur

Menyusun fitur turunan untuk meningkatkan representasi data, antara lain total

penilaian pelanggan (*TotalRating*), rasio pengeluaran terhadap pendapatan (*SpendToIncomeRatio*), dan indikator waktu tunggu (*LongWait*).

3. Pembagian Dataset

Dataset dibagi menjadi data pelatihan (80%) dan data pengujian (20%) menggunakan metode *stratified split* untuk menjaga proporsi kelas target.

4. Penyeimbangan Data

Menerapkan teknik *oversampling* pada data pelatihan dengan rasio 0,8 untuk mengatasi ketidakseimbangan kelas dan meningkatkan kemampuan model dalam mengenali pola kelas minoritas.

5. Optimasi Hiperparameter

Melakukan pencarian parameter optimal menggunakan *RandomizedSearchCV* dengan skema *5-fold cross-validation* guna meningkatkan performa dan stabilitas model.

6. Pelatihan Model

Melatih model menggunakan algoritma XGBoost (*XGBClassifier*) dengan penyesuaian bobot kelas melalui parameter *scale_pos_weight*.

7. Optimasi Ambang Batas

Menentukan nilai *threshold* optimal dengan mengevaluasi rentang nilai 0,3–0,7 untuk memperoleh skor F1 terbaik.

8. Evaluasi Model

Mengevaluasi performa model pada data pengujian menggunakan metrik akurasi, F1-score, ROC-AUC, dan *confusion matrix*.

3.3. Metode Pengambilan Keputusan TOPSIS

Setelah tahap prediksi, DSS melakukan perhitungan Multi-Criteria Decision Making (MCDM) menggunakan TOPSIS (Technique for Order Preference by Similarity to Ideal Solution) untuk menentukan alternatif strategi terbaik berdasarkan beberapa kriteria yang diperoleh dari hasil prediksi model XGBoost.

Metode TOPSIS merupakan metode MCDM yang menilai setiap alternatif berdasarkan jarak ke solusi ideal positif dan negatif, sehingga alternatif terbaik adalah yang paling dekat ke ideal positif dan paling jauh dari ideal negatif. TOPSIS banyak digunakan dalam DSS untuk masalah dengan kriteria yang saling bertentangan karena mampu memberikan peringkat yang objektif dan terukur terhadap alternatif keputusan.

Langkah perhitungan TOPSIS adalah sebagai berikut:

1. Menyusun *decision matrix* berdasarkan nilai kriteria dari prediksi XGBoost.
2. Melakukan normalisasi matriks keputusan.

3. Mengalikan matriks normalisasi dengan bobot kriteria.
4. Menentukan *ideal best* dan *ideal worst* untuk setiap kriteria.
5. Menghitung jarak tiap alternatif terhadap *ideal best* dan *ideal worst*.
6. Menghitung nilai preferensi dan meranking alternatif strategi.

3.4. Integrasi XGBoost dan TOPSIS dalam Decision Support System

Integrasi metode XGBoost dan TOPSIS dalam Decision Support System (DSS) pada penelitian ini dirancang untuk menghubungkan proses analisis prediktif dengan pengambilan keputusan multikriteria secara sistematis. XGBoost digunakan sebagai model prediksi untuk mengolah data survei kepuasan pelanggan yang diunggah oleh pengguna melalui sistem, sehingga menghasilkan nilai prediksi yang merepresentasikan tingkat kepuasan pelanggan atau skor kriteria yang relevan bagi strategi pengembangan penjualan restoran.

Nilai prediksi yang dihasilkan oleh XGBoost selanjutnya disusun ke dalam *decision matrix* dan digunakan sebagai input pada metode TOPSIS untuk mengevaluasi dan meranking alternatif strategi berdasarkan kedekatannya terhadap solusi ideal positif dan jaraknya dari solusi ideal negatif. Hasil perhitungan TOPSIS berupa nilai preferensi digunakan sebagai dasar rekomendasi strategi terbaik, sehingga DSS mampu memberikan keputusan yang objektif, terukur, dan berbasis data bagi staf strategi atau pemasaran restoran.

BAB IV

HASIL DAN DISKUSI

4.1. Hasil Pengolahan Data dan Pembentukan Model

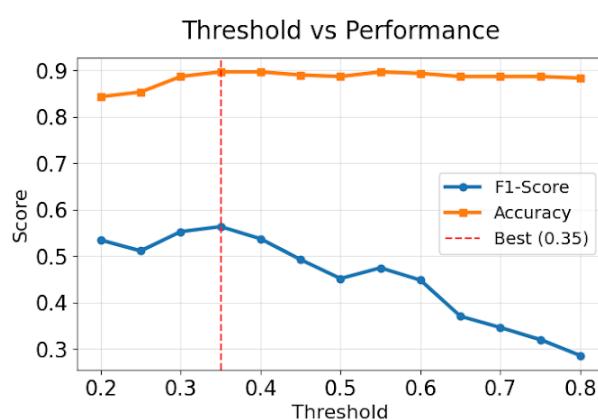
Dataset yang digunakan dalam penelitian ini telah melalui tahap prapemrosesan data yang meliputi penanganan nilai hilang, transformasi variabel kategorikal menjadi numerik, serta rekayasa fitur lanjutan. Proses ini bertujuan untuk meningkatkan kualitas data dan memperkaya representasi informasi yang digunakan dalam pelatihan model.

Tahap rekayasa fitur menghasilkan sejumlah fitur tambahan yang merepresentasikan perilaku pelanggan, pola konsumsi, karakteristik kunjungan, serta interaksi antar variabel. Dengan adanya fitur-fitur ini, model diharapkan mampu menangkap pola non-linear yang kompleks dalam data kepuasan pelanggan restoran.

Distribusi variabel target menunjukkan adanya ketidakseimbangan kelas antara pelanggan dengan tingkat kepuasan rendah dan tinggi. Oleh karena itu, strategi penanganan data tidak seimbang diterapkan pada tahap pelatihan model untuk meningkatkan kemampuan prediksi terhadap kelas minoritas.

4.2. Hasil Pelatihan dan Optimasi Model XGBoost

Model prediksi kepuasan pelanggan dibangun menggunakan algoritma Extreme Gradient Boosting (XGBoost) dan dioptimasi untuk meningkatkan kinerja klasifikasi, khususnya pada kelas kepuasan tinggi. Optimasi dilakukan melalui kombinasi oversampling sintetis, penyesuaian bobot kelas, serta pencarian hiperparameter menggunakan metode RandomizedSearchCV.



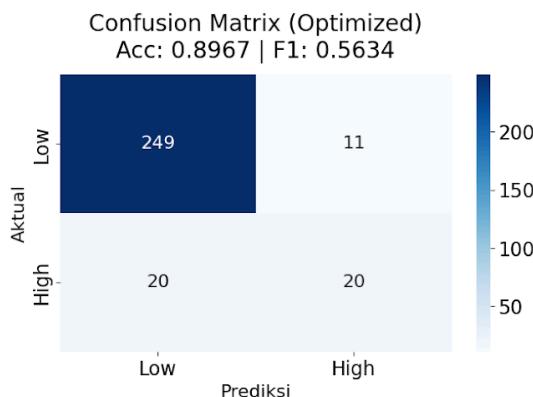
Evaluasi model pada data uji menunjukkan bahwa model XGBoost yang telah dioptimasi menghasilkan performa yang baik. Model mencapai akurasi sebesar 89,67%, yang menunjukkan kemampuan klasifikasi yang tinggi secara keseluruhan. Selain itu, nilai F1-score sebesar 0,5634 menunjukkan peningkatan keseimbangan antara *precision*

dan *recall* dibandingkan model sebelum optimasi. Nilai ROC-AUC sebesar 0,7917 mengindikasikan bahwa model memiliki kemampuan diskriminasi yang baik dalam membedakan pelanggan dengan tingkat kepuasan rendah dan tinggi.

Peningkatan performa model setelah optimasi menunjukkan bahwa strategi penanganan data tidak seimbang dan penyesuaian parameter model memberikan dampak positif terhadap kualitas prediksi.

4.3. Analisis Hasil Prediksi dan Confusion Matrix

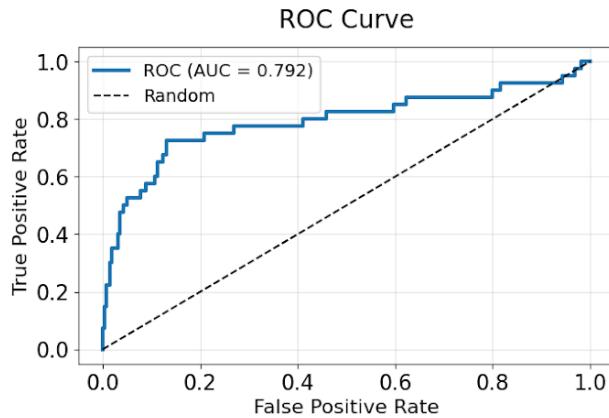
Berdasarkan confusion matrix, model XGBoost mampu mengklasifikasikan sebagian besar data uji dengan tepat. Jumlah prediksi benar pada kelas kepuasan rendah menunjukkan tingkat akurasi yang tinggi, sementara pada kelas kepuasan tinggi model menunjukkan peningkatan kemampuan deteksi dibandingkan sebelum optimasi.



Meskipun performa pada kelas minoritas masih lebih rendah dibandingkan kelas mayoritas, penurunan jumlah kesalahan klasifikasi pada kelas kepuasan tinggi menunjukkan bahwa model menjadi lebih sensitif dalam mengenali pelanggan dengan tingkat kepuasan tinggi. Hal ini penting dalam konteks sistem pendukung keputusan, karena informasi mengenai pelanggan dengan kepuasan tinggi dapat digunakan sebagai dasar perumusan strategi pengembangan restoran.

4.4. Analisis Kurva ROC dan Threshold Keputusan

Kurva ROC digunakan untuk mengevaluasi kemampuan model dalam membedakan dua kelas pada berbagai nilai ambang keputusan. Nilai ROC-AUC yang diperoleh menunjukkan bahwa model memiliki performa yang jauh lebih baik dibandingkan klasifikasi acak.



Selain itu, dilakukan analisis terhadap nilai threshold keputusan untuk menentukan titik keseimbangan terbaik antara *precision* dan *recall*. Hasil analisis menunjukkan bahwa penggunaan threshold yang dioptimasi mampu meningkatkan sensitivitas model terhadap kelas kepuasan tinggi tanpa menurunkan akurasi secara signifikan. Pendekatan ini memperkuat peran model sebagai komponen prediktif yang stabil dalam sistem pendukung keputusan.

4.5. Implementasi Sistem Pendukung Keputusan Berbasis Web

Sistem pendukung keputusan pada penelitian ini diimplementasikan dalam bentuk aplikasi berbasis web menggunakan *framework* Streamlit (<https://restaurantstrategy.streamlit.app/>). Aplikasi dirancang dengan antarmuka yang sederhana dan mudah digunakan, sehingga pengguna tidak memerlukan latar belakang teknis untuk menjalankan sistem.

Sistem menyediakan fitur unggah dataset dalam format CSV serta mekanisme mapping kolom, dimana pengguna dapat menyesuaikan kolom-kolom pada dataset yang diunggah dengan atribut yang dibutuhkan oleh sistem. Pendekatan ini memungkinkan sistem untuk menganalisis dataset dengan struktur yang berbeda-beda tanpa perlu perubahan kode.

The screenshot shows the Streamlit application interface. On the left is a dark sidebar with a logo, the title 'Restaurant Strategy Recommendation System', and navigation links: Home, User Guide, Analysis Dashboard, and About. The main area has a white background with a yellow header bar containing the text 'Step 1: Upload Dataset Pelanggan'. Below this is a sub-section titled 'Upload file CSV yang berisi data pelanggan restoran Anda. Sistem akan otomatis mencocokkan kolom dengan features yang dibutuhkan.' It includes a 'Pilih file CSV Anda' section with a 'Drag and drop file here' input field, a 'Browse files' button, and a file preview for 'example_dataset.csv' (245.0B). To the right is a 'Tips:' box with three bullet points: 'Format: CSV', 'Minimal 5 kolom match', and 'Data bersih tanpa missing values banyak'. A green success message 'Dataset berhasil dimuat!' is displayed. At the bottom is a 'Preview Dataset' section showing a table with columns: CustomerID, ServiceRating, FoodRating, AmbianceRating, WaitTime, AverageSpend, VisitFrequency, LoyaltyProgramMember. Two rows of data are visible: Row 0 (CustomerID: 0, others: 4.5, 4, 4.2, 15, 50000, 5, 1) and Row 1 (CustomerID: 1, others: 2, 3.8, 4.5, 3.5, 25, 75000, 12, 1).

Step 2: Mapping Features

Sistem akan otomatis mencocokkan kolom dataset Anda dengan features model ML.

Total Features Model	Features Matched	Match Rate
42	12	28.6%

Dataset valid! 12/42 fitur berhasil di-map.

Detail Mapping per Kategori

Model Feature	Dataset Column	Type	Description
0 VisitFrequency	VisitFrequency	Benefit	Frekuensi kunjungan
1 AverageSpend	AverageSpend	Cost	Rata-rata pengeluaran

Step 3: Analisis Feature Importance

Melihat feature mana yang paling berpengaruh terhadap kepuasan pelanggan.

Top 10 Most Important Features

Features	Importance (%)
AmbianceRating	1.2%
RatingRange	2.5%
WaitTime	2.5%
TotalRating	2.6%
AvgRating	2.9%
FoodRating	4.7%
MinRating	7.2%
MaxRating	10.6%
VisitFrequency	10.6%
LoyaltyProgramMember	49.1%

Insight

Feature dengan importance tertinggi adalah faktor yang paling mempengaruhi kepuasan pelanggan di restoran Anda.

- #1 LoyaltyProgramMember **49.1% importance**
- #2 VisitFrequency **10.6% importance**
- #3 MaxRating

Step 4: Analisis TOPSIS & Rekomendasi

Mendapatkan ranking strategi bisnis terbaik menggunakan metode TOPSIS.

Total Strategi	Kriteria Evaluasi	Features Analyzed
53	13	12

Ranking Strategi

Top 10 Strategi Rekomendasi

Strategi	Rank
G4: Win-back Reminder System	Rank 10
G6: Predictive Menu Alerts	Rank 9
B5: Premium Pav Latar	Rank 8

Top 3 Rekomendasi Strategi Terbaik

Strategi-strategi ini paling cocok dengan profil pelanggan Anda

Rank 1: G5: Gamification Rewards

Deskripsi Strategi

Program loyalitas berbasis gamifikasi dengan elemen seperti lencana, pencapaian, papan peringkat, tantangan, dan misi. Pendekatan ini membuat proses mendapatkan hadiah menjadi lebih menyenangkan dan tidak sekadar transaksional. Sangat efektif untuk generasi milenial dan Gen Z serta membangun keterikatan emosional pelanggan.

Langkah Implementasi

1. Achievement badges: contoh "Early Bird" dan "Night Owl"
2. Daily quests: tantangan harian untuk bonus poin
3. Streak rewards: bonus untuk kunjungan berturut-turut
4. Leaderboard: peringkat bulanan dengan hadiah eksklusif
5. Limited edition badges: lencana khusus musiman atau event

Setelah proses mapping kolom dilakukan, sistem secara otomatis menjalankan tahapan pra-pemrosesan, prediksi menggunakan model XGBoost, serta perhitungan lanjutan untuk menghasilkan rekomendasi. Dengan alur ini, sistem bersifat fleksibel dan adaptif terhadap berbagai dataset, sekaligus tetap mempertahankan konsistensi proses analisis dan pengambilan keputusan.

4.6. Diskusi Hasil

Hasil penelitian menunjukkan bahwa penggunaan XGBoost sebagai model prediksi mampu memberikan performa yang baik dalam memprediksi tingkat kepuasan pelanggan restoran. Model yang dihasilkan memiliki akurasi tinggi dan kemampuan diskriminasi yang memadai, sehingga layak digunakan sebagai komponen analisis dalam sistem pendukung keputusan.

Implementasi sistem dalam bentuk aplikasi Streamlit memberikan nilai tambah dari sisi fleksibilitas dan kemudahan penggunaan. Dengan adanya fitur mapping kolom dan alur analisis otomatis, sistem dapat digunakan untuk berbagai dataset tanpa kehilangan relevansi analisis. Pendekatan ini mendukung tujuan penelitian untuk membangun DSS yang tidak hanya akurat secara teknis, tetapi juga praktis dan adaptif dalam konteks penggunaan nyata.

BAB V

KESIMPULAN

5.1. Kesimpulan

Sistem Rekomendasi Strategi Restoran yang dikembangkan pada penelitian ini berhasil diimplementasikan sebagai sistem pendukung keputusan berbasis web dengan mengintegrasikan model Machine Learning dan metode pengambilan keputusan multikriteria TOPSIS. Sistem mampu mengolah data survei kepuasan pelanggan dan menghasilkan prediksi tingkat kepuasan yang selanjutnya digunakan sebagai dasar dalam penyusunan rekomendasi strategi pengembangan restoran secara objektif dan terukur.

Model prediksi kepuasan pelanggan menunjukkan performa yang baik setelah dilakukan prapemrosesan data, rekayasa fitur, penanganan ketidakseimbangan kelas, serta optimasi hiperparameter. Penerapan penyesuaian nilai ambang prediksi juga terbukti meningkatkan kemampuan model dalam mendeteksi kelas kepuasan tinggi. Implementasi sistem dalam bentuk aplikasi Streamlit dengan fitur pemetaan kolom dataset secara fleksibel menjadikan sistem adaptif terhadap berbagai struktur data dan mudah digunakan oleh pengguna non-teknis.

5.2. Saran

Pengembangan sistem ke depan dapat difokuskan pada peningkatan performa model prediksi dengan memperluas jumlah dan variasi dataset, serta dengan mengeksplorasi algoritma Machine Learning lain yang berpotensi memberikan hasil prediksi yang lebih optimal. Selain itu, evaluasi model dapat diperluas dengan metrik dan skenario pengujian tambahan untuk memastikan kestabilan performa pada data dengan karakteristik yang berbeda.

Dari sisi sistem, disarankan untuk menambahkan fitur visualisasi dan analisis interaktif yang lebih mendalam, serta melakukan integrasi langsung dengan data operasional restoran agar rekomendasi yang dihasilkan semakin relevan dengan kondisi nyata. Pengujian sistem secara langsung kepada pengguna juga perlu dilakukan untuk mengevaluasi aspek kegunaan (*usability*) dan memastikan bahwa sistem benar-benar mendukung pengambilan keputusan strategis di lingkungan bisnis restoran.

DAFTAR PUSTAKA

- Dairu, X., & Shilong, Z. (2021). Machine learning model for sales forecasting by using XGBoost. In *Proceedings of the 2021 IEEE International Conference on Consumer Electronics and Computer Engineering (ICCECE)* (pp. 480–483). IEEE.
<https://doi.org/10.1109/ICCECE51280.2021.9342304>
- Kavlakoglu, E., & Russi, E. (2025, November 17). *XGBoost*. IBM.
<https://www.ibm.com/think/topics/xgboost>
- Kharoua, R. E. (2024). *Predict restaurant customer satisfaction dataset* [Data set]. Kaggle.
<https://doi.org/10.34740/kaggle/dsv/8743147>
- Kovari, A. (2024). AI for decision support: Balancing accuracy, transparency, and trust across sectors. *Information*, 15(11), 725.
<https://doi.org/10.3390/info15110725>
- Madanchian, M., & Taherdoost, H. (2023). A comprehensive guide to the TOPSIS method for multi-criteria decision making. *SSRN Electronic Journal*.
https://papers.ssrn.com/sol3/papers.cfm?abstract_id=4626727
- Muin, A. A., & Amin, M. (2022). Sistem pendukung keputusan pemilihan kuliner terpopuler di Kalimantan Selatan dengan metode TOPSIS. *Jurnal Informatika Universitas Pamulang*.
<https://openjournal.unpam.ac.id/index.php/informatika/article/view/12923>
- Rogawati, N., Susilawati, I., & Witanti, A. (2023). Restaurant recommendation decision support system using TOPSIS system. *EXSACT-A*.
<https://doi.org/10.36722/exc.v1i1.2248>
- Singgalen, Y. A. (2025). Penerapan metode TOPSIS sebagai pendukung keputusan pemilihan layanan akomodasi di destinasi wisata pulau. *Jurnal Media Informatika Budidarma*.
<https://ejurnal.stmik-budidarma.ac.id/index.php/mib/article/view/6530>
- XGBoost Development Team. (n.d.). *Introduction to boosted trees*. XGBoost Documentation.
<https://xgboost.readthedocs.io/en/stable/tutorials/model.html>